

Estudo da Influência das Features e do Desempenho dos Classificadores na Detecção de Anomalias em Redes

João Lucas Oliveira Mota¹, João Lucas Rodrigues da Silva², José Alberto Rodrigues Neto²

¹ Departamento de Engenharia de Teleinformática – Universidade Federal do Ceará (UFC)
Fortaleza – CE – Brasil

² Departamento de Computação – Universidade Federal do Ceará (UFC)
Fortaleza – CE – Brasil

{jlucasoliveira2002}@gmail.com, {joao.lsilva, jose.alberto}@alu.ufc.br

Abstract.

Resumo. *CHANGE ME*

1. Introdução

CHANGE ME

Este artigo investiga a influência da seleção de atributos e do desempenho de diferentes classificadores na detecção de anomalias em tráfego de redes de computadores.

2. Dataset e pré-processamento

2.1. Dataset

O conjunto de dados utilizado foi obtido a partir da plataforma Kaggle, no repositório *Network Intrusion Detection*, disponibilizado publicamente por Sampada Bhosale [Bhosale 2018].

O dataset foi construído a partir da simulação de um ambiente de rede militar típico da Força Aérea dos Estados Unidos, desenvolvido para representar diferentes tipos de tráfego de rede, incluindo tanto comunicações legítimas quanto diversos tipos de ataques. Cada instância do conjunto de dados representa uma conexão de rede, contendo atributos como a quantidade de bytes transmitidos pela origem, a duração da conexão e outros parâmetros, conforme descrito na tabela apresentada no Apêndice.

Por fim, após as simulações realizadas de forma supervisionada, as conexões foram classificadas como tráfego normal ou como intrusão, fazendo com que a variável alvo seja do tipo binária, assumindo os valores *Normal* ou *Anomalia*.

2.2. Pré-processamento

A aplicação da Análise de Componentes Principais (PCA) como etapa de pré-processamento tem se mostrado eficaz para a redução da dimensionalidade dos dados sem perda significativa de informação. Estudos indicam que o PCA é capaz de preservar cerca de 99% da variância original mesmo com reduções superiores a 50% no número de atributos, conforme observado por Santos e Miani [Santos and Miani 2025].

Neste artigo, foram realizadas diferentes análises utilizando modelos de aprendizagem de máquina, com o objetivo de identificar as *features* de maior importância para

cada modelo. Em seguida, buscando simular um cenário mais próximo de um ambiente real, no qual nem sempre todos os atributos estão disponíveis para os algoritmos de análise, foram conduzidos testes com a remoção das *features* mais relevantes. Essa abordagem teve como objetivo analisar a influência de cada atributo no desempenho dos modelos, bem como avaliar a robustez de cada método frente à ausência parcial de informações.

3. Metodologia

3.1. Modelos Utilizados

3.1.1. Random Forest

O Random Forest (RF) é um algoritmo de aprendizado de máquina supervisionado baseado em conjuntos de árvores de decisão, no qual múltiplas árvores são treinadas a partir de subconjuntos aleatórios dos dados e dos atributos, combinando suas previsões por meio de votação majoritária. Sua utilização neste trabalho se deve à robustez frente a dados de alta dimensionalidade, à capacidade de modelar relações não lineares e à possibilidade de analisar a importância das *features*, características relevantes para problemas de detecção de intrusão em redes [Breiman 2001].

3.1.2. K-Nearest Neighbors

Outro modelo utilizado foi o K-Nearest Neighbors (KNN). Esse modelo se diferencia dos demais por não realizar uma etapa explícita de aprendizado a partir dos dados de treinamento. Em vez disso, ele armazena as instâncias conhecidas e classifica uma nova entrada com base na similaridade em relação a um número arbitrário (K) de exemplos mais próximos previamente registrados [Cover and Hart 1967].

3.1.3. Isolation Forest

O Isolation Forest (IF) é um algoritmo de aprendizado de máquina não supervisionado, projetado especificamente para a detecção de anomalias (ou outliers) em conjuntos de dados. A escolha do Isolation Forest foi motivada pelo fato de que, em alguns cenários, não é possível obter todos os dados rotulados necessários para a detecção de intrusões em redes. Dessa forma, buscou-se avaliar se o IF seria capaz de identificar anomalias mesmo na ausência parcial dos rótulos utilizados no treinamento [Liu et al. 2008].

3.1.4. Multilayer Perceptron (MLP)

O Multilayer Perceptron (MLP) é um modelo de rede neural artificial supervisionado, composto por camadas de neurônios interconectados que aplicam transformações não lineares sobre os dados de entrada. A escolha do MLP foi motivada por sua capacidade de aprender padrões complexos no tráfego de rede, sendo adequado para a detecção de intrusões que apresentam comportamentos sutis.

Neste trabalho, o modelo foi avaliado em dois cenários: um utilizando todas as *features* disponíveis e outro com a remoção da *feature* mais influente identificada no mod-

elo de melhor resultado, com o objetivo de analisar o impacto da redução de atributos em seu desempenho.

Ressalta-se que o desempenho do MLP depende fortemente da escolha adequada de hiperparâmetros e do pré-processamento dos dados, conforme discutido na literatura [Haykin 2009].

4. Resultados e Discussão

4.1. Resultados com K-Nearest Neighbors

Para o modelo KNN, foram realizados alguns testes, com os resultados mais precisos foram encontrados com $K = 1$, resultando em um F1-Score de 0.9946 e uma acurácia de 0.9960. Provavelmente, esse comportamento ocorre devido à grande quantidade de dados disponíveis para cada entrada de treinamento, o que torna a maioria dos ataques mais evidentes. Valores superiores de K levaram ao sobreajuste e ao decréscimo progressivo do desempenho do modelo.

Após uma análise baseada na remoção individual de cada atributo, observou-se que o parâmetro *hot* foi o mais decisivo para o modelo, reduzindo o F1-Score para 0.9931 quando removido. Outra informação relevante é que oito atributos, quando removidos, aumentaram a precisão do modelo. Após essa remoção, o F1-Score atingiu 0.9960, sendo o atributo *diff_srv_rate* o mais prejudicial, cuja exclusão resultou em um aumento de 0.0005 pontos no F1-Score.

Table 1. Métricas de desempenho do KNN

Métrica	Classe Normal	Classe Anomalia
Precision	0.99	0.99
Recall	0.99	0.99
F1-Score	0.99	0.99
Support	4034	3524

4.2. Resultados com Isolation Forest

O Isolation Forest se mostrou ineficiente quando comparado aos outros modelos utilizados durante a pesquisa, apresentando a menor acurácia (0.748). Entretanto, a acurácia não é a métrica mais confiável em conjuntos de dados desbalanceados, o que é comum em problemas de detecção de anomalias, pois pode ser inflacionada pela capacidade do modelo em classificar corretamente a classe majoritária (tráfego normal). Dessa forma, uma análise mais aprofundada torna-se necessária.

Table 2. Métricas de desempenho do Isolation Forest

Métrica	Classe Normal	Classe Anomalia
Precision	1.00	0.65
Recall	0.53	1.00
F1-Score	0.69	0.79
Support	2690	2349

Como pode ser observado na Tabela 2, todos os eventos classificados como normais eram, de fato, normais. A principal dificuldade do modelo esteve na identificação correta das anomalias, apresentando precisão de 65% (0.65) ao rotular eventos como intrusão. Além disso, considerando todos os eventos analisados, o modelo foi capaz de identificar corretamente apenas 53% (0.53) dos eventos normais, o que indica a geração de um elevado número de falsos positivos, isto é, eventos normais classificados como ataques.

Por outro lado, o Isolation Forest não apresentou o problema de gerar falsos negativos, uma vez que ataques não foram classificados como eventos normais. Em síntese, o modelo apresenta dificuldades em verificar se um evento é realmente normal, gerando falsos positivos que podem ocasionar retrabalho para equipes de segurança, as quais precisam analisar manualmente eventos normais identificados como anômalos.

4.3. Resultados com Random Forest

O Random Forest apresentou o melhor desempenho entre todos os modelos avaliados quando utilizado com o conjunto completo de atributos, alcançando uma acurácia de 0.9975. O modelo demonstrou excelente capacidade de generalização, classificando corretamente tanto o tráfego normal quanto as intrusões, o que evidencia seu elevado poder discriminativo em um cenário de detecção de anomalias em redes.

Conforme apresentado na Tabela 3, os valores de Precision, Recall e F1-Score foram iguais a 1.00 para ambas as classes, indicando a ausência praticamente total de falsos positivos e falsos negativos. Esses resultados reforçam a robustez do Random Forest e justificam sua utilização como modelo de referência para a análise de importância dos atributos. Nesse contexto, a feature *src_bytes* foi identificada como a mais influente no modelo, motivando sua remoção em uma segunda etapa experimental.

Com o objetivo de avaliar a robustez do Random Forest frente a conjuntos de dados incompletos, o modelo foi reavaliado após a exclusão da feature *src_bytes*. Nesse cenário, observou-se uma queda significativa no desempenho, com a acurácia reduzida para 0.9630, conforme apresentado na Tabela 4. Embora o modelo ainda apresente bons resultados globais, nota-se uma redução no Recall da classe normal (0.93), indicando um aumento na taxa de falsos positivos, ou seja, eventos normais classificados incorretamente como anomalias.

Esse comportamento evidencia a forte dependência do Random Forest em relação a atributos altamente informativos e reforça a importância da qualidade e da completude dos dados em aplicações de detecção de intrusões em redes. Além disso, os resultados obtidos corroboram a motivação deste trabalho em investigar como diferentes modelos de aprendizado de máquina reagem à ausência de atributos relevantes no conjunto de dados.

4.4. Resultados com MLP

O Multilayer Perceptron foi avaliado em dois cenários distintos: um utilizando todas as features disponíveis no conjunto de dados e outro com a remoção da feature *src_bytes*, identificada como a mais influente no modelo Random Forest, que apresentou o melhor desempenho geral. O objetivo dessa análise foi avaliar o impacto da ausência de uma

Table 3. Métricas de desempenho do Random Forest (dataset completo)

Métrica	Classe Normal	Classe Anomalia
Precision	1.00	1.00
Recall	1.00	1.00
F1-Score	1.00	1.00
Support	3523	4035

Table 4. Métricas de desempenho do Random Forest (dataset reduzido, sem *src_bytes*)

Métrica	Classe Normal	Classe Anomalia
Precision	0.99	0.94
Recall	0.93	0.99
F1-Score	0.96	0.97
Support	3523	4035

feature relevante no desempenho do MLP, simulando cenários em que o conjunto de dados pode estar incompleto.

No cenário completo, o MLP obteve uma acurácia de 0.9960, apresentando desempenho equilibrado entre as classes. A classe Anomalia apresentou precisão de 0.9969 e recall de 0.9946, enquanto a classe Normal obteve precisão de 0.9953 e recall de 0.9973, resultando em F1-Scores superiores a 0.995 para ambas as classes, conforme apresentado na Tabela 5.

Table 5. Métricas de desempenho do MLP com todas as features

Métrica	Classe Anomalia	Classe Normal
Precision	0.9969	0.9953
Recall	0.9946	0.9973
F1-Score	0.9957	0.9963
Support	3523	4035

Após a remoção da feature *src_bytes*, o MLP apresentou uma leve redução de desempenho, com acurácia de 0.9952. Observa-se que, embora o recall da classe Anomalia tenha aumentado para 0.9969, houve redução na precisão dessa classe, passando para 0.9929. Para a classe Normal, verificou-se comportamento inverso, com aumento da precisão e redução do recall. Ainda assim, os valores de F1-Score permaneceram elevados para ambas as classes, indicando que o modelo manteve desempenho consistente mesmo com a remoção de uma feature altamente relevante em outro classificador, conforme mostrado na Tabela 6.

De forma geral, os resultados indicam que o MLP é relativamente robusto à remoção de uma feature altamente influente em outro modelo, apresentando apenas pequenas variações nas métricas de desempenho. Esse comportamento reforça a capacidade do MLP de aprender representações distribuídas dos dados, reduzindo sua dependência de atributos individuais.

Table 6. Métricas de desempenho do MLP sem a feature *src_bytes*

Métrica	Classe Anomalia	Classe Normal
Precision	0.9929	0.9973
Recall	0.9969	0.9938
F1-Score	0.9949	0.9955
Support	3523	4035

5. Conclusão

CHANGE ME

Este trabalho analisou a influência da seleção de atributos e do desempenho de diferentes classificadores na detecção de anomalias em redes de computadores.

References

- Bhosale, S. (2018). Network intrusion detection. Kaggle. Acesso em 2025.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.
- Cover, T. M. and Hart, P. E. (1967). Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, 13(1):21–27.
- Haykin, S. (2009). *Neural Networks and Learning Machines*. Prentice Hall, 3 edition.
- Liu, F. T., Ting, K. M., and Zhou, Z.-H. (2008). Isolation forest. In *Proceedings of the IEEE International Conference on Data Mining (ICDM)*, pages 413–422. IEEE.
- Santos, K. C. and Miani, R. S. (2025). Impacto da redução de dimensão e seleção de atributos na generalização de modelos de detecção de intrusão. In *Anais do Simpósio Brasileiro de Redes de Computadores e Sistemas Distribuídos (SBRC)*, Uberlândia, MG, Brazil. SBC.

Apêndice A — Descrição Completa do Dataset

Table 7. Descrição completa dos atributos do dataset de intrusão em redes

Atributo	Descrição
duration	Duração da conexão de rede
protocol_type	Protocolo utilizado na conexão (TCP, UDP ou ICMP)
service	Serviço de rede acessado
flag	Estado da conexão conforme o protocolo
src_bytes	Quantidade de bytes enviados pela origem
dst_bytes	Quantidade de bytes enviados pelo destino
land	Indica se origem e destino possuem mesmo IP e porta
wrong_fragment	Número de fragmentos incorretos
urgent	Número de pacotes marcados como urgentes
hot	Indicadores de comportamentos suspeitos
num_failed_logins	Número de tentativas de login malsucedidas
logged_in	Indica se o login foi realizado com sucesso
num_compromised	Número de condições comprometidas
root_shell	Indica obtenção de shell com privilégio root
su_attempted	Tentativas de uso do comando <i>su</i>
num_root	Número de acessos root
num_file_creations	Número de arquivos criados
num_shells	Número de shells abertos
num_access_files	Número de acessos a arquivos sensíveis
num_outbound_cmds	Número de comandos externos enviados
is_host_login	Indica login como host
is_guest_login	Indica login como convidado
count	Conexões com o mesmo host em janela de tempo
srv_count	Conexões com o mesmo serviço em janela de tempo
serror_rate	Taxa de erros SYN
srv_serror_rate	Taxa de erros SYN para o serviço
rerror_rate	Taxa de erros de resposta
srv_rerror_rate	Taxa de erros de resposta para o serviço
same_srv_rate	Taxa de conexões para o mesmo serviço
diff_srv_rate	Taxa de conexões para serviços diferentes
srv_diff_host_rate	Taxa de serviços acessando hosts distintos
dst_host_count	Número de conexões para o mesmo host destino
dst_host_srv_count	Número de conexões para o mesmo serviço no host
dst_host_same_srv_rate	Taxa de serviços iguais para o host destino
dst_host_diff_srv_rate	Taxa de serviços diferentes para o host destino
dst_host_same_src_port_rate	Taxa de conexões com mesma porta de origem
dst_host_srv_diff_host_rate	Taxa de serviços com hosts distintos
dst_host_serror_rate	Taxa de erros SYN no host destino
dst_host_srv_serror_rate	Taxa de erros SYN por serviço no host destino
dst_host_rerror_rate	Taxa de erros de resposta no host destino
dst_host_srv_rerror_rate	Taxa de erros de resposta por serviço no host destino